Frontier Agent

Operación visual de aplicaciones desconocidas

Problema, alcance y supuestos

Ejecutar tareas por píxeles y entrada VNC en apps nunca vistas: cambios exactos, sin duplicados ni acciones adicionales, con resultado veraz. El evaluador entrega escritorio por tarea y lo resetea a los cinco minutos. Leer dimensiones y fecha de la app. Modelo visual permitido y concurrencia aún por validar. Excluimos DOM/API internos, archivos remotos y entrenamiento por aplicación: solo hay acceso visual. El agente no recibe respuestas esperadas ni usa reset/check en evaluación.

Arquitectura, memoria y trazabilidad

FastAPI/Pydantic autentica y acepta en menos de dos segundos. PostgreSQL conserva tareas, resultados e interacciones; SQLAlchemy asíncrono/psycopg y Alembic gestionan tablas propias. Tarea y outbox se confirman juntos; dispatcher publica referencias a Redis. LangGraph orquesta y persiste checkpoints por tarea con AsyncPostgresSaver; AsyncPostgresStore guarda conocimiento permitido. LangChain integra modelos/tools. Orquestador con operador, verificador y recuperador, delegados por hitos; un ejecutor valida y envía acciones por VNC directo (AsyncVNC y puente WSS, probado en notebook). Ciclo: observar, actuar y verificar. Historial por tarea/ejecución/agente, capturas privadas referenciadas; credenciales fuera del modelo y memoria de negocio aislada entre evaluaciones.

Decisiones y escalabilidad

VNC directo evita navegador de noVNC/Playwright; revisar licencia/mantenimiento. **API y workers separados** evitan peticiones largas, a costa de cola/coordinación. **Especialistas por hitos** separan responsabilidades frente al agente monolítico, pero añaden latencia. **PostgreSQL desde demo** evita usar la cola como único estado durable, a costa de pools/migraciones.

Demo: VPS con Compose, proxy HTTPS, API, worker, PostgreSQL, Redis y volumen; punto único de fallo. Producción: réplicas API, scheduler con cuotas, workers y gateways VNC escalables, almacenamiento privado y LangSmith. Escalar por escritorios independientes y cuota del modelo. Un ejecutor por escritorio: gateway valida propiedad/versión, workers sin VNC directo. Antes de reasignar, confirmar cierre anterior; un lease expirado no basta.

Casos difíciles, fallos y límite de tiempo

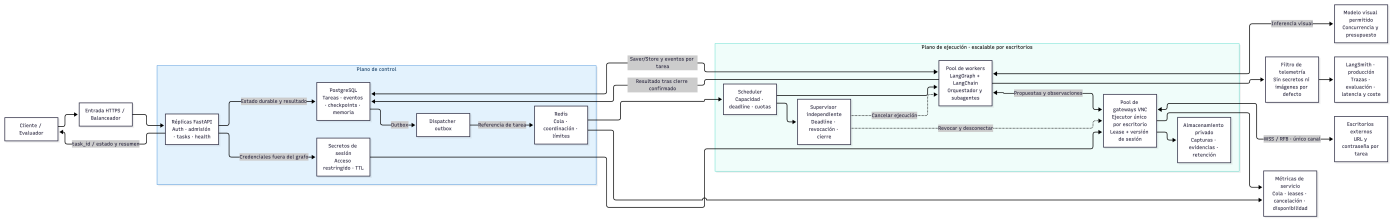
Homónimos: fallar sin modificar y explicar identificadores. Edición: preservar otros campos, seleccionar todo y verificar persistencia. Clics de 150–200 ms y espera de repintado. Consultas sin mutación; exportación con filtros verificados. Texto de pantalla no amplía el alcance. Guardado incierto: reobservar; checkpoints no hacen idempotente un clic. Supervisor independiente: bloquear acciones desde 270 s, cancelar pendientes y desconectar antes del estado terminal; cierre objetivo menor a 285 s, incluida cola. Descartar propuestas tardías; no reanudar tras reset/plazo. Evidencia insuficiente: fallar con razón; verificación visual no garantiza conocer todo el estado interno.

Plan de medición y observabilidad

E1–E5, tres repeticiones desde reset: creación, edición mínima, consulta, exportación y rechazo de homónimos. Metas: **15/15 correctas**, **3/3 rechazos** y **0** cambios extras, duplicados, falsos éxitos o secretos. Harness combina check con estado/resumen. Aceptación **<2 s**, cierre **<285 s** y acciones posteriores **0**. Preguntas: línea `respuesta:` con valor primero y dos datos separados por `;`.

Variar controles, popups, paginación y fecha; probar modelo lento, desconexión tras guardar, worker caído y propuesta vieja. Medir éxito, espera, duración, pasos, coste y cancelación con destinos independientes/compartidos. Solo transporte e interacción VNC comprobados; cifras anteriores son metas. Demo: eventos en PostgreSQL. Producción: LangSmith registra trazas filtradas por tarea/agente/tool; excluir secretos, URLs e imágenes por defecto, sin bloquear tareas. LangGraph ejecuta; LangSmith observa.

Arquitectura de producción



Arquitectura de producción exportada desde Mermaid. Imagen de alta resolución entregada también por separado.